网络爬虫的“盗亦有道”

WS02

嵩天

www.python123.org

The Website is the API ...

robots.txt

网络爬虫排除标准

Requests

自动爬取HTML页面

自动网络请求提交

掌握定向网络数据爬取和网页解析的基本能力

python

弹指之间 · 享受创新

Python网络爬虫与信息提取

O4X -Tian

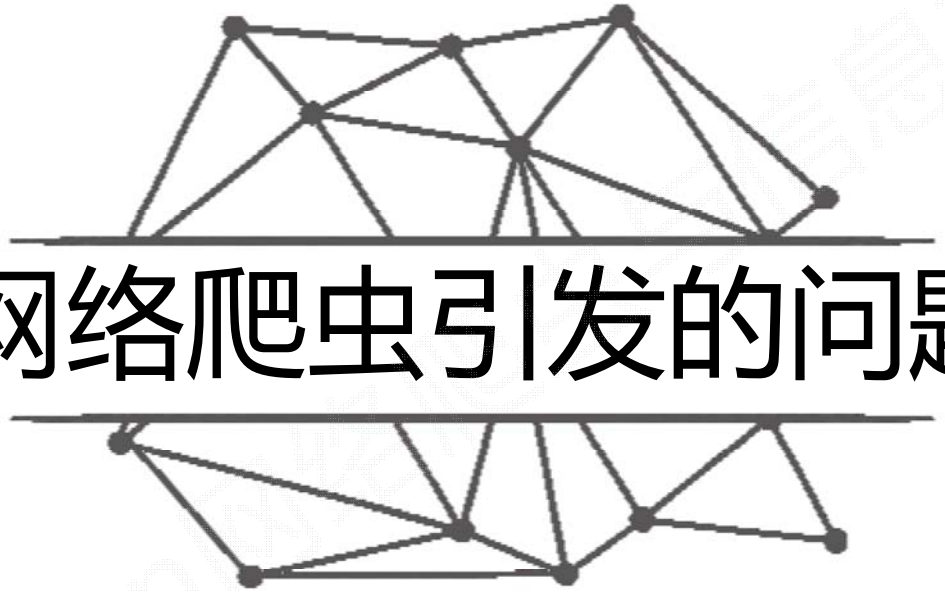

网络爬虫引发的问题

网络爬虫的尺寸

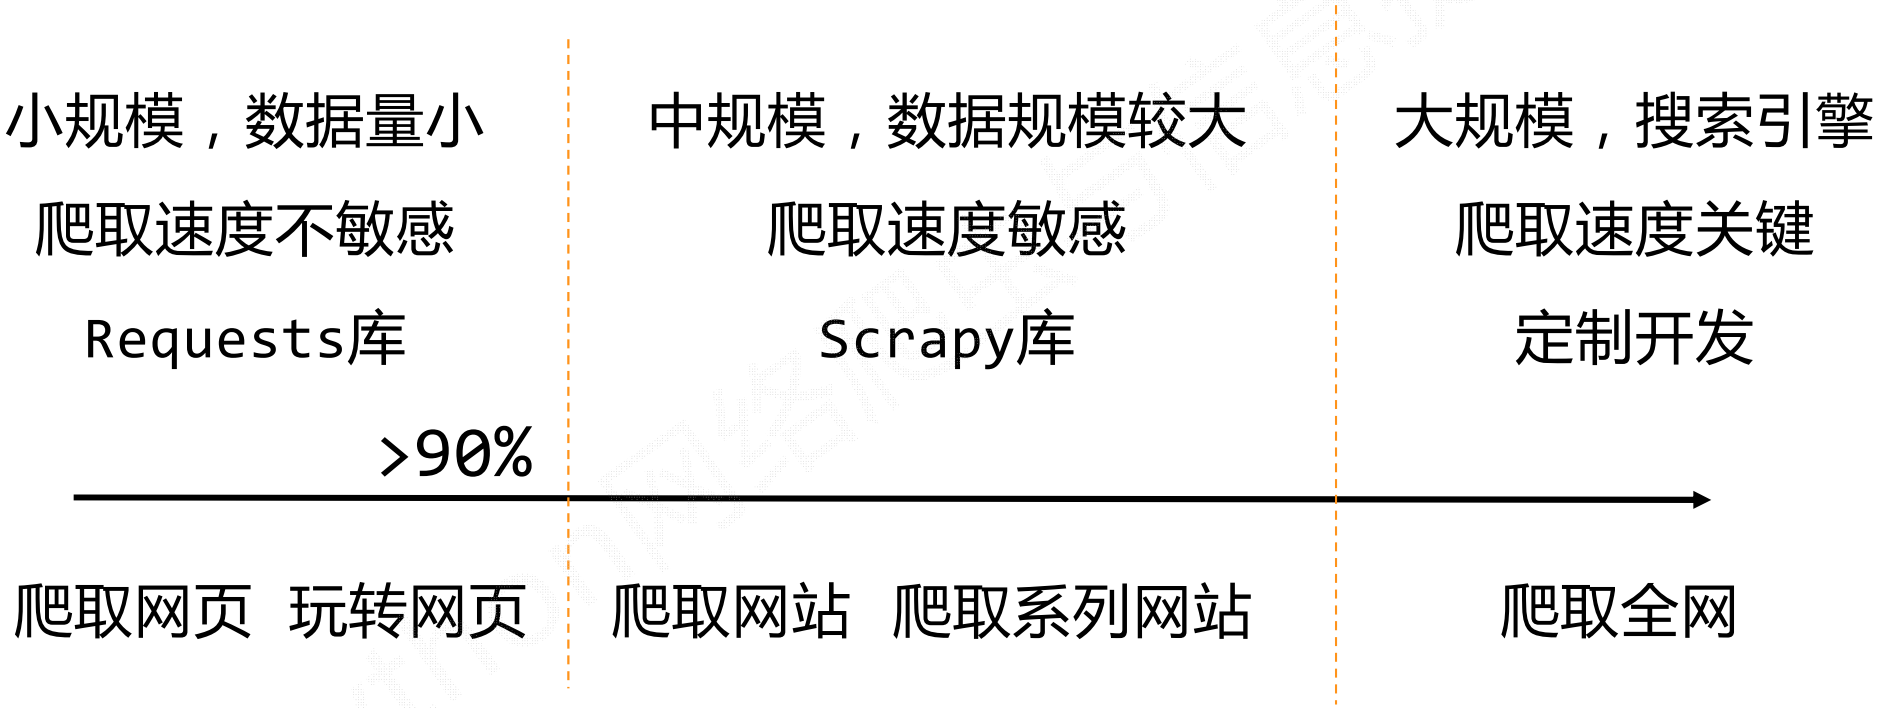
小规模，数据量小
爬取速度不敏感
Requests库
中规模，数据规模较大
爬取速度敏感
Scrapy库
大规模，搜索引擎
爬取速度关键
定制开发
>90%
爬取网页 玩转网页
爬取网站 爬取系列网站
爬取全网

网络爬虫的“性能骚扰”

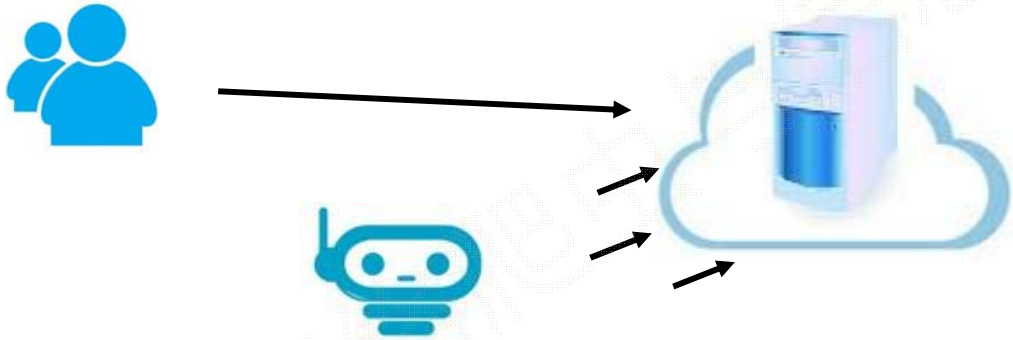

Web服务器默认接收人类访问

受限于编写水平和目的，网络爬虫将会为Web服务器带来巨大的资源开销

网络爬虫的法律风险

服务器上的数据有产权归属

网络爬虫获取数据后牟利将带来法律风险

网络爬虫的隐私泄露

网络爬虫可能具备突破简单访问控制的能力，获得被保护数据从而泄露个人隐私

网络爬虫引发的问题

性能骚扰

法律风险

隐私泄露

网络爬虫的限制

- 来源审查：判断User-Agent进行限制

  检查来访HTTP协议头的User-Agent域，只响应浏览器或友好爬虫的访问

- 发布公告：Robots协议

  告知所有爬虫网站的爬取策略，要求爬虫遵守

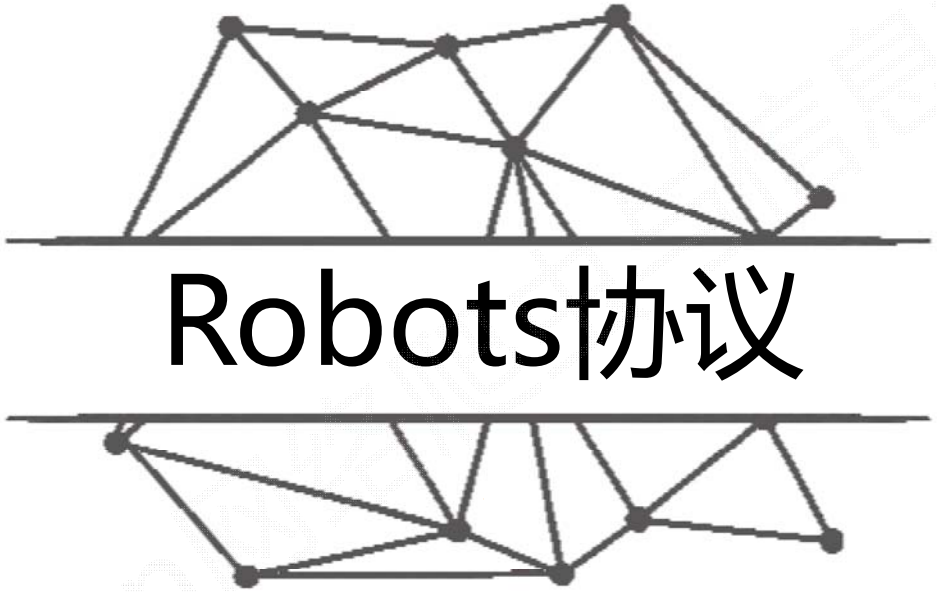

Robots协议

Robots协议

Robots Exclusion Standard，网络爬虫排除标准

作用：

网站告知网络爬虫哪些页面可以抓取，哪些不行

形式：

在网站根目录下的robots.txt文件

案例：京东的Robots协议

https://www.jd.com/robots.txt

```
User-agent: *
Disallow: /?*
Disallow: /pop/*.html
Disallow: /pinpai/*.html?*
User-agent: EtaoSpider
Disallow: /
User-agent: HuihuiSpider
Disallow: /
User-agent: GwdangSpider
Disallow: /
User-agent: WochachaSpider
Disallow: /
```

```
# 注释，*代表所有，/代表根目录
User-agent: *
Disallow: /
```

Robots协议基本语法

案例：真实的Robots协议

http://www.baidu.com/robots.txt

http://news.sina.com.cn/robots.txt

http://www.qq.com/robots.txt

http://news.qq.com/robots.txt

http://www.moe.edu.cn/robots.txt （无robots协议）

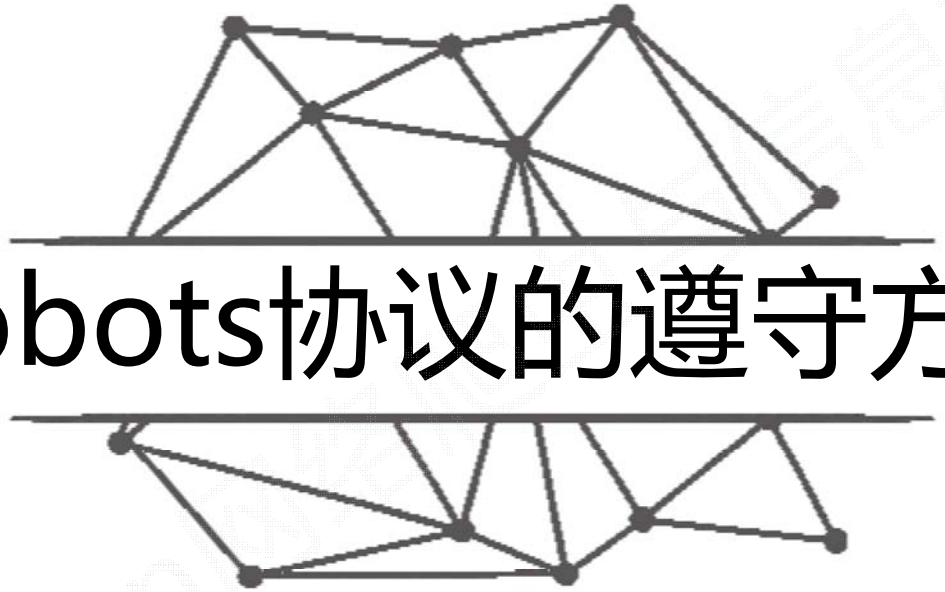

Robots协议的遵守方式

实际操作中，该如何遵守Robots协议？

Robots协议的使用

网络爬虫：

自动或人工识别robots.txt，再进行内容爬取

约束性：

Robots协议是建议但非约束性，网络爬虫可以不遵守，但存在法律风险

对Robots协议的理解

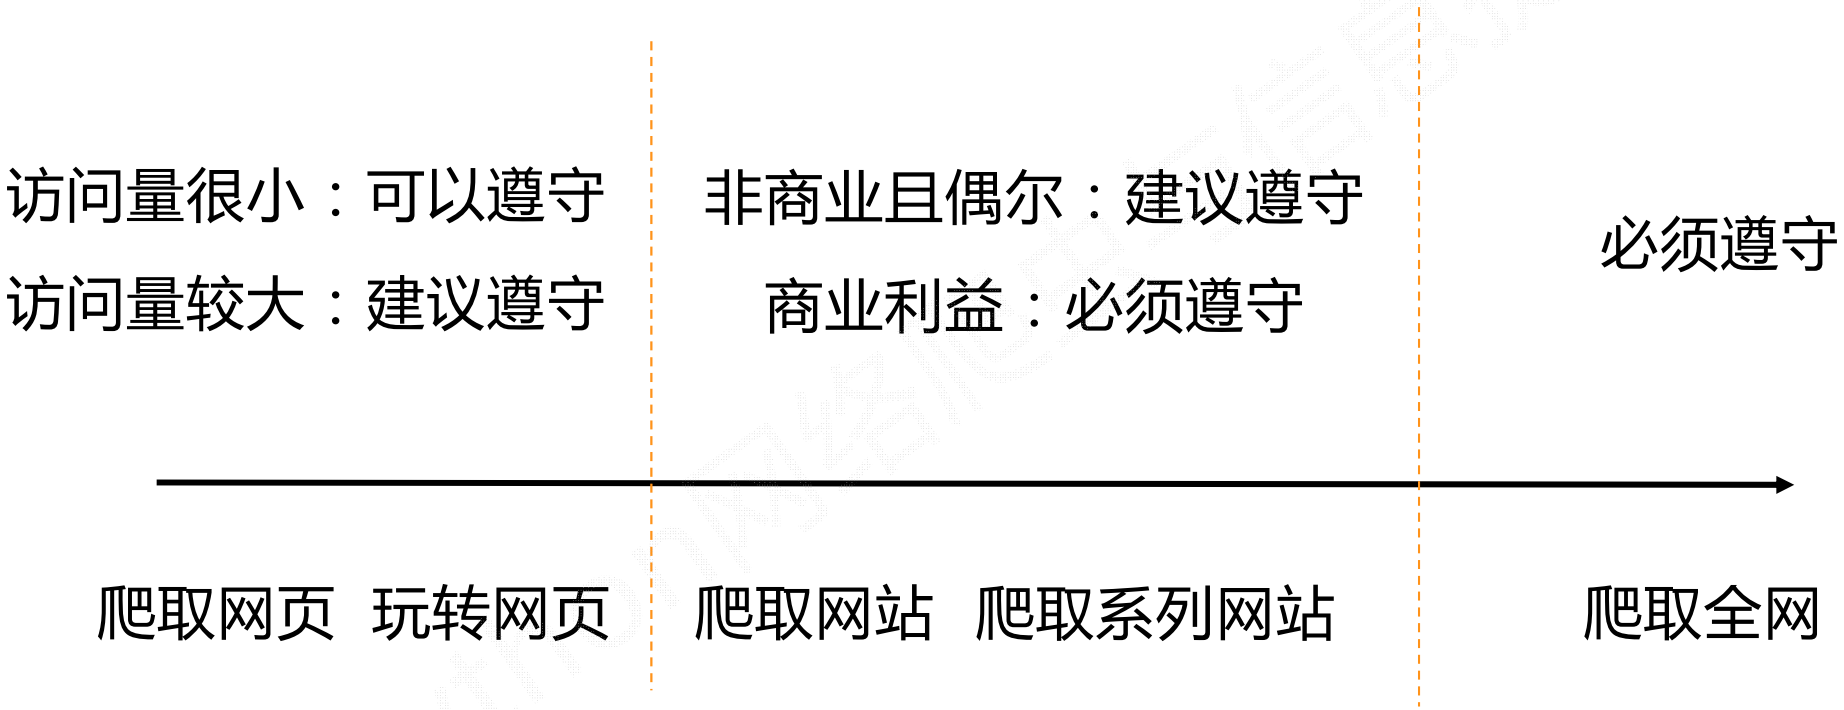

原则：类人行为可不参考Robots协议

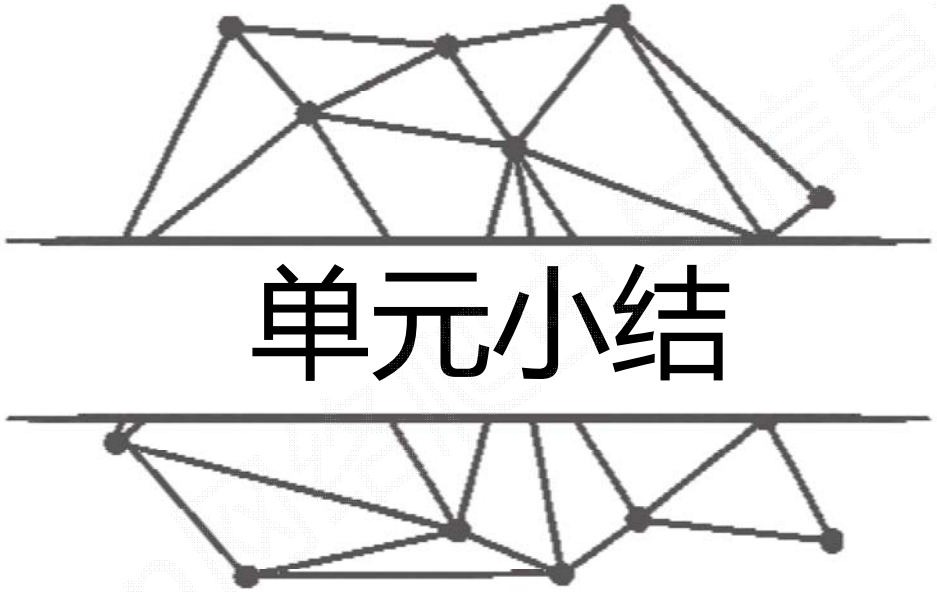

单元小结

网络爬虫“盗亦有道”

```
# 注释，*代表所有，/代表根目录
User-agent: *
Disallow: /
```

Robots协议基本语法

Robots协议的使用原则